“Análise de toxicidade na comunidade gamer do YouTube com o uso de modelos de linguagem”

Aluno: Israel Matias do Amaral
Orientadora: Helen

UFOP

icea

DECSI
DEPARTAMENTO DE COMPUTAÇÃO E SISTEMAS

Índice

1. Introdução
2. ~~Trabalhos Relacionados~~
3. ~~Oportunidades~~
4. Metodologia
5. Análise Exploratória de Dados
6. Experimentos Iniciais
7. Próximos Passos
8. Referências
9. ~~Apêndice (Gráficos)~~

1. Introdução

1.1 Definição de toxicidade

- "Comentários tóxicos são mensagens rudes, desrespeitosas ou irracionais que podem fazer com que uma pessoa abandone uma discussão” **(JIGSAW, 2017 apud FORTUNA; NUNES, 2018)**
- É o termo mais adequado para uma abordagem abrangente e pode servir como categoria superior para "linguagem ofensiva" e **"discurso de ódio"**.
- **Fortuna e Nunes (2018)** destacam que o discurso de ódio pode ocorrer com "diferentes estilos linguísticos, mesmo em formas sutis ou quando o **humor** é usado",

1.2 O debate sobre os limites do humor

Condenação de Léo Lins reacende debate sobre limites do humor e da liberdade de expressão; veja o que dizem juristas

Justiça condenou humorista a 8 anos e 3 meses de prisão, além do pagamento de multa e indenização por danos morais. Defesa alega que não houve intenção de ofender ninguém.

Por Redação GloboNews e g1 SP

04/06/2025 15h29 · Atualizado há uma semana

1.3 Cenário gamer no YouTube

- Com o crescimento da cultura gamer e das transmissões ao vivo no YouTube, cresce também a presença de comentários tóxicos.
- Muitos desses comentários são expressos por meio de ironias e **expressões codificadas**, o que dificulta sua detecção automática. **(OLIVEIRA et al., 2023)**

1.4 Expressões Codificadas

1.5 Expressões codificadas na mídia

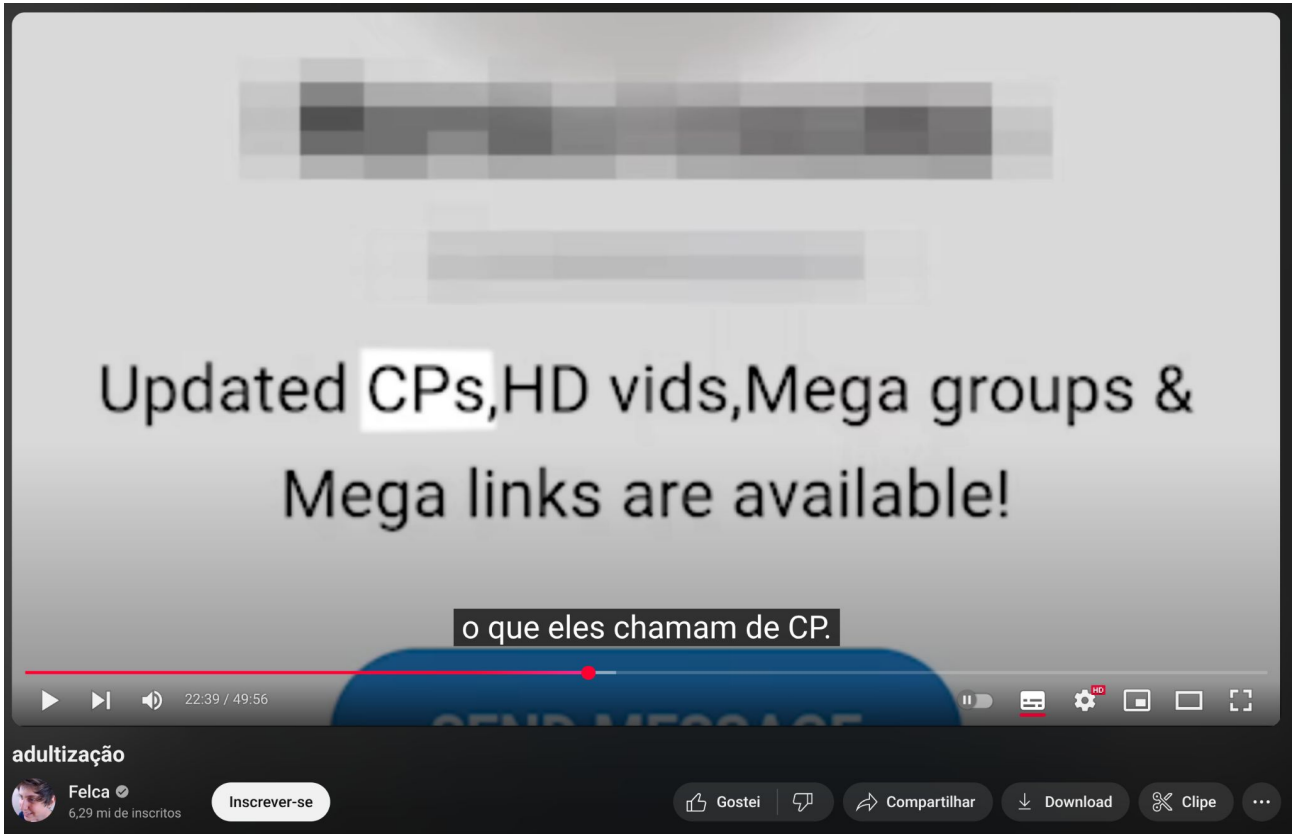

1.6 O foco deste trabalho

- Este trabalho foca em transmissões ao vivo realizadas por uma **sub comunidade gamer do YouTube**, composta por streamers como *luangameplay* e *renanplay*, conhecidos por adotar um estilo de humor mais ácido, politicamente incorreto e usar **linguagem codificada.**
- Essa comunidade apresenta alto engajamento — alguns canais chegam a mais de **1,4 milhões** de inscritos e registram **mais de mil** espectadores por transmissão.

~~2. Trabalhos Relacionados~~

~~3. Oportunidades~~

4. Metodologia

4.1. Ordem Cronológica da Metodologia

1. Coleta de Dados
2. Rotulagem de Dados
3. Pré-processamento de Dados
4. Treinamento de Modelo
5. Classificação do Discurso Tóxico
6. Análise Quantitativa e Qualitativa Final

4.6 Metodologia de coleta dos dados

Para coletar o chat das transmissões ao vivo usando a API oficial do YouTube foi necessário criar um Monitor de Lives.

- Aplicação Python que detecta novas lives automaticamente;
- Inicia a coleta do chat ao vivo e metadados da transmissão.

Lives ativas

Canal	Título (até 60 car.)	Duração da coleta (horas)
Diego Sheipado	🔴 IRL: POCAHONTAS E SHEIPADO NA FEIRA DOS NORDETINOS COM @Ga	02:40
REnanPLAY	BORA ZERAR STELLAR BLADE PC	02:30
CAVALÃO 2	A FAMOSA LIVE PROIBIDA DE MUSIQUINHA. VENHAM QUE HOJE PROMET	02:00
LUANGAMEPLAY	FINALMENTE OPEREI - MUDEI DE SEXO (TO VIVO)	01:50
BiahKov	💜 SABADOU DOS GURIS! (altos react)	01:50

4.7 Resultado de coleta dos dados

- Período: **14/06/2025** 21:38 a **14/08/2025** 20:59
- Total de mensagens: **1.740.704**
- Total de lives: **231**
- Canais analisados: **7**

4.8 Quantidade de lives e mensagens por canal

Canal	Live Count	Total Mensagens
Canal do Celinho	15	61.294
Canal do Ronaldinho	33	7.550
Diego Sheipado	38	98.164
Fábio Streamer	55	39.784
LUANGAMEPLAY	35	532.186
REnanPLAY	48	984.899
Wallace Gamer	7	16.827
Total	**231**	**1.740.704**

5. Análise Exploratória de Dados

Análise 1: Estatísticas Globais por Transmissão

Variável	Média	Mediana
quantidade_mensagens	7.535,52	2.171,00
tamanho_mensagem	40,39	18,00
tempo_entre_mensagens	1,54	0,38

- Variância significativa nas métricas, com médias e medianas indicando possível distribuição assimétrica.

Análise 2: Quantidade de mensagens por transmissão

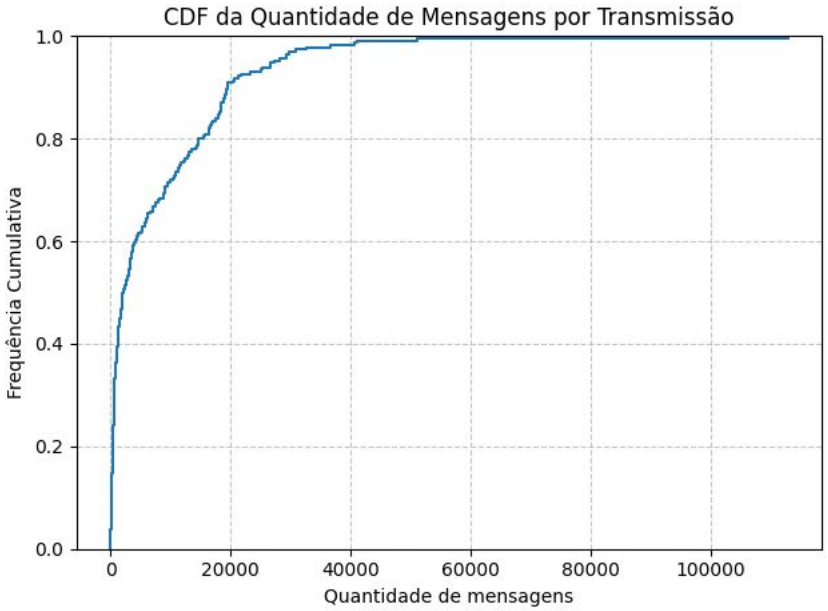

Insight:

- A maioria das transmissões tem engajamento moderado, enquanto algumas apresentam volumes excepcionalmente altos, sugerindo a necessidade de considerar outliers em análises futuras.

Análise 3: Quantidade de mensagens por canal

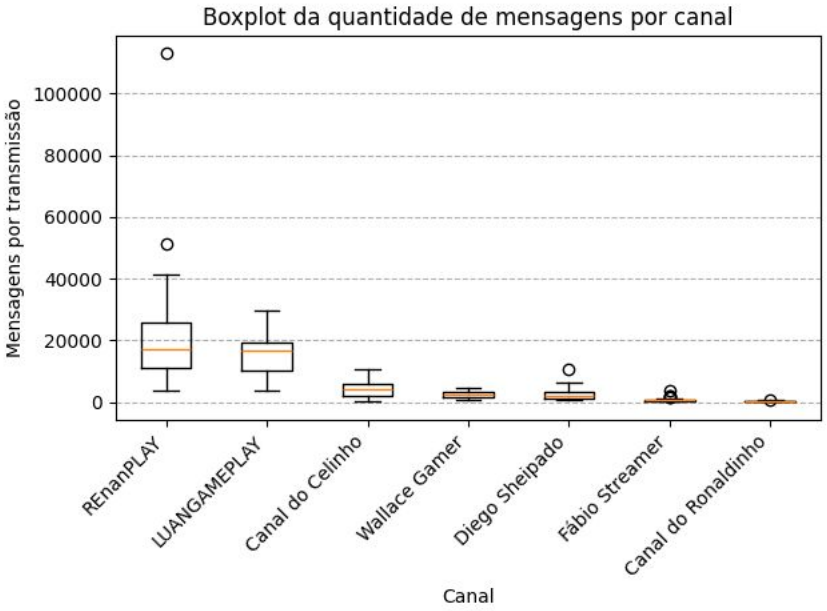

Insight:

- Os canais mostram padrões variados de engajamento, com alguns exibindo maior volume e variabilidade, enquanto outros mantêm transmissões mais homogêneas.

Análise 3: Quantidade de mensagens por canal

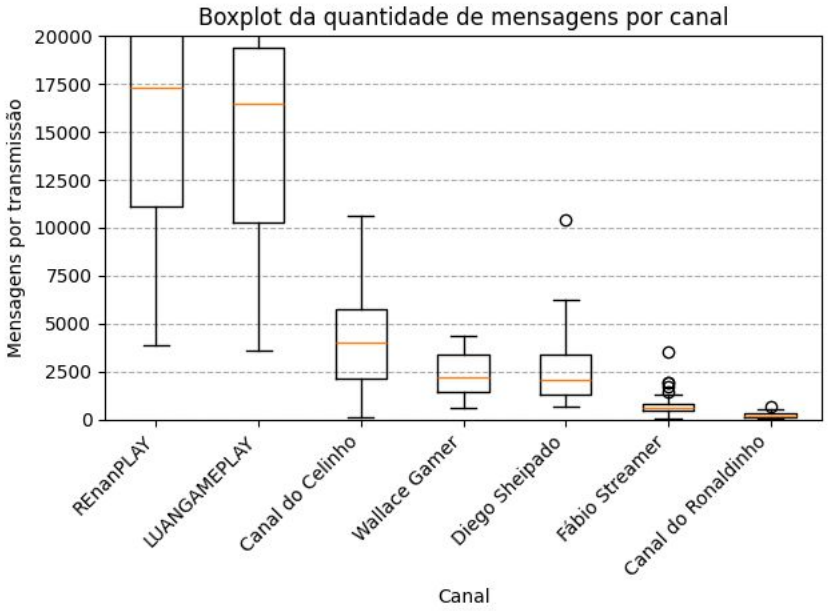

Insight:

- Os canais mostram padrões variados de engajamento, com alguns exibindo maior volume e variabilidade, enquanto outros mantêm transmissões mais homogêneas.

Análise 4: Análise Temporal (Hora do Dia)

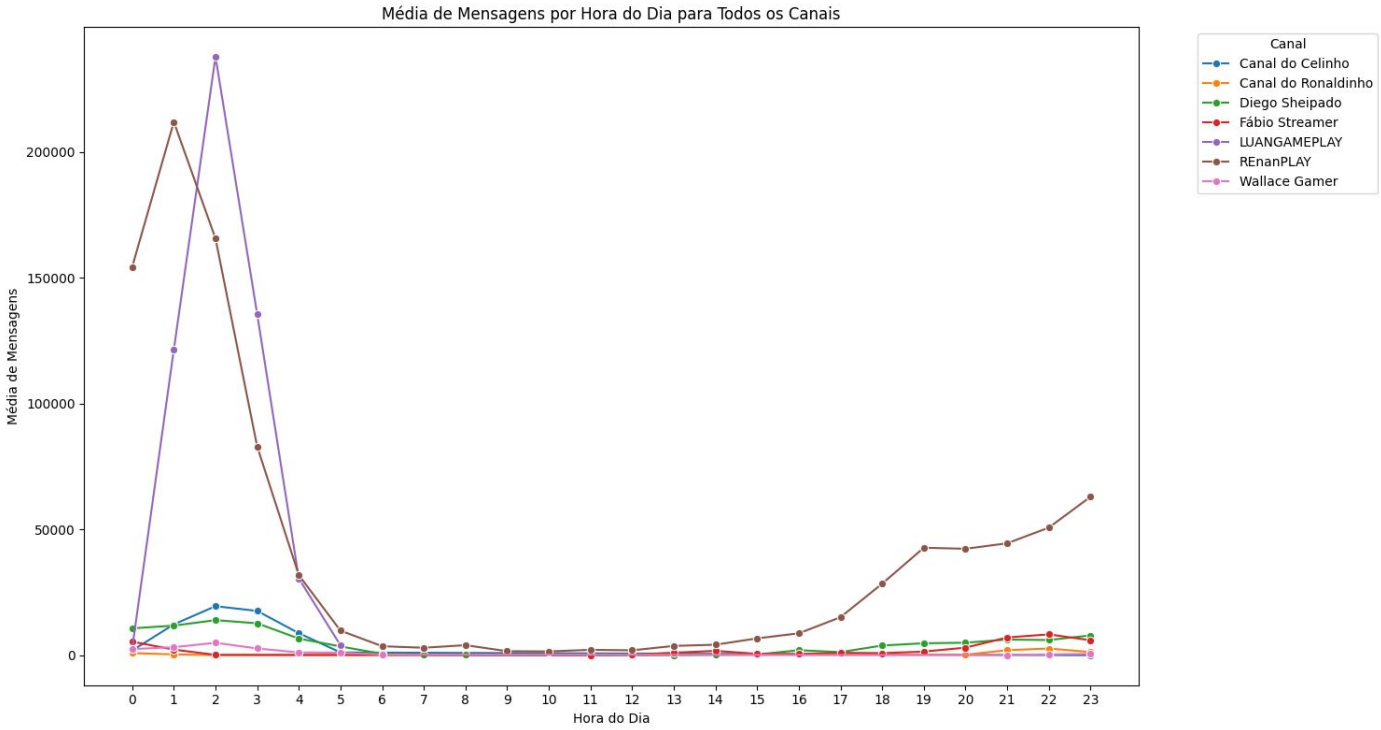

Análise 4: Análise Temporal (Dia da Semana)

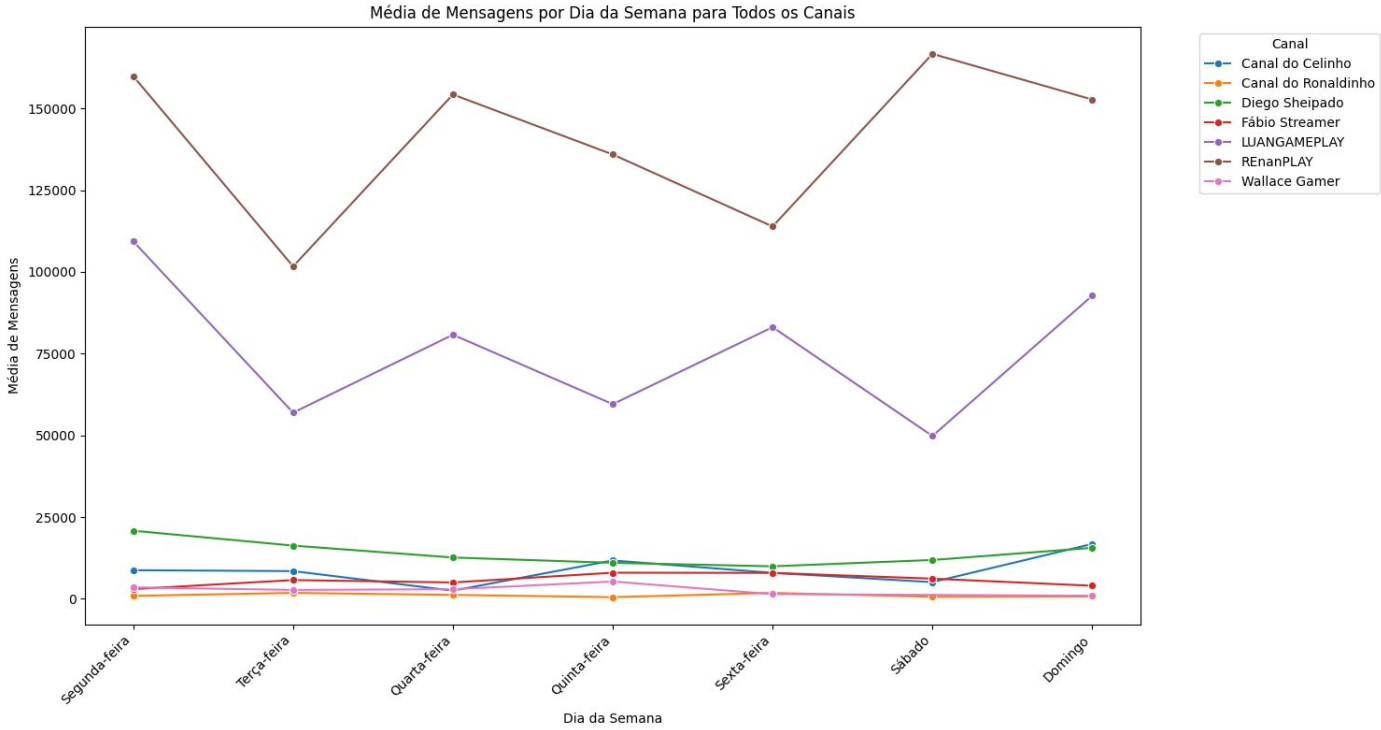

6. Experimentos Iniciais

6.1 Rotulagem

- **Fonte:** Amostra de 3.000 comentários de chats ao vivo de uma comunidade gamer brasileira, bem ativa, conhecida pelo seu contexto único.
- **Rotulagem:** Realizada manualmente, seguindo um guia formal baseado nas diretrizes do YouTube para garantir consistência e qualidade.
- **Distribuição:**
  - Não Tóxico: 2.783 comentários (92.8%)
  - Tóxico: 217 comentários (7.2%)
- **Conclusão:** O dataset é altamente desbalanceado, refletindo um cenário real e tornando o F1-Score a métrica de avaliação mais adequada.

6.3 Experimento Inicial: Projeto Fatorial

Metodologia: Foi empregado um Projeto Fatorial de 2 fatores, cada um com 2 níveis.

Modelo Classificador	Tipo de Pré-processamento
Perspective API (genérico)	Texto Bruto (sem tratamento)
Modelo BERT (especializado)	Texto Padrão (minúsculas, sem quebras de linha)

Variável Resposta: F1-Score Médio (Binário, Foco na Classe "Tóxico"), obtido a partir de 30 replicações via Bootstrap para garantir a robustez estatística dos resultados.

6.4 Experimento Inicial: Resultados

Pré-processamento	Perspective API	Modelo BERT (Fine-tuned)
Bruto	**0.3273**	**0.6632**
Padrão	**0.3467**	**0.6857**

- **Efeito do Modelo:** Massivo. O BERT (F1 ≈ 0.67) superou a Perspective API (F1 ≈ 0.34) em 97.78%, validando a importância do fine-tuning.
- **Efeito do Pré-processamento:** Marginal, mas consistente. A melhora de 0.6632 para 0.6857 (+0.0225) no BERT é muito similar à observada na Perspective API.

7. Próximos Passos

7. Próximos Passos

- Melhorar o guia de rotulagem (Codebook), visando deixá-lo mais robusto.
- Pesquisar e explorar técnicas de rotulagem para mais de um anotador.
- Pesquisar e explorar técnicas para melhorar a performance do classificador de toxicidade (early stopping, enriquecimento da classe minoritária, dentre outros).
- Aplicar o classificador ao dataset completo de 1.740.704 comentários.
- Análise Quantitativa e Qualitativa Final.

8. Referências

8. Referências

FORTUNA, P.; NUNES, S. A Survey on Automatic Detection of Hate Speech in Text. **ACM Computing Surveys**, [S. l.], v. 51, n. 4, art. 85, p. 1-30, jul. 2018. Disponível em: https://doi.org/10.1145/3232676. Acesso em: 25 ago. 2025.

GEETANJALI; KUMAR, M. Exploring hate speech detection: challenges, resources, current research and future directions. **Multimedia Tools and Applications**, [S. l.], 2025. Disponível em: https://doi.org/10.1007/s11042-025-20716-2. Acesso em: 25 ago. 2025.

OLIVEIRA, A. S. et al. How Good Is ChatGPT For Detecting Hate Speech In Portuguese? *In*: SIMPÓSIO BRASILEIRO DE TECNOLOGIA DA INFORMAÇÃO E DA LINGUAGEM HUMANA, 14., 2023, Porto Alegre. **Anais do XIV Simpósio Brasileiro de Tecnologia da Informação e da Linguagem Humana**. Porto Alegre, RS: SBC, 2023. p. 94–103.

POOKPANICH, P.; SIRIBORVORNRATANAKUL, T. Offensive language and hate speech detection using deep learning in football news live streaming chat on YouTube in Thailand. **Social Network Analysis and Mining**, [S. l.], v. 14, n. 18, 2024. Disponível em: https://doi.org/10.1007/s13278-023-01183-9. Acesso em: 25 ago. 2025.

RAMOS, G. et al. A comprehensive review on automatic hate speech detection in the age of the transformer. **Social Network Analysis and Mining**, [S. l.], v. 14, n. 204, 2024. Disponível em: https://doi.org/10.1007/s13278-024-01361-3. Acesso em: 25 ago. 2025.

SCHMID, U. K. Humorous hate speech on social media: A mixed-methods investigation of users' perceptions and processing of hateful memes. **New Media & Society**, [S. l.], v. 27, n. 3, p. 1588–1606, 2025. Disponível em: https://doi.org/10.1177/14614448231198169. Acesso em: 25 ago. 2025.

~~9. Apêndice (Gráficos)~~

Obrigado pela atenção!

“Análise de toxicidade na comunidade gamer do YouTube com o uso de modelos de linguagem”

UFOP

icea

DECSI
DEPARTAMENTO DE COMPUTAÇÃO E SISTEMAS

fim.